


Robustez e Funcionamento no Mundo Real

Inteligência Artificial em Sistemas Embebidos

O PARADOXO LABORATORIAL

99%

Precisão típica no *Test Set* laboratorial.



Modelos otimizados para distribuições estáticas e controladas colapsam perante a entropia dos ambientes reais.

MÓDULO 1

Dataset Shift

Definição, Causas e Tipologia de Desvios

O Pressuposto i.i.d.

Modelos clássicos assumem que os dados de treino e teste são *Independentes e Identicamente Distribuídos* (i.i.d.).

$$P_{\text{treino}}(X, Y) \approx P_{\text{teste}}(X, Y)$$

A Quebra do Pressuposto

O *Dataset Shift* ocorre quando a distribuição conjunta difere no ambiente de inferência embebido.

$$P_{\text{treino}}(X, Y) \neq P_{\text{real}}(X, Y)$$

Taxonomia do Dataset Shift



Covariate Shift

$P(X)$ muda, $P(Y|X)$ fixo.

Alteração estatística nas variáveis independentes (entradas).



Prior Shift

$P(Y)$ muda, $P(X|Y)$ fixo.

Alteração drástica na frequência marginal das classes.



Concept Shift

$P(Y|X)$ muda, $P(X)$ fixo.

Modificação fundamental na relação causal entrada-saída.

Fontes de Variabilidade em Ambientes Embebidos



Degradação Sensorial

Desvios de calibração, drift térmico e envelhecimento dos transdutores.



Condições Ambientais

Variações extremas de iluminação, saturação ótica e reflexos não previstos.



Interferência Física

Vibrações mecânicas severas e ruído eletromagnético induzido.

DADOS NÃO VISTOS

Comportamento Fora da Distribuição (OOD)


O Cenário Crítico Exposição a amostras estatisticamente distantes do conjunto de treino.

Falhas Silenciosas Previsões catastroficamente erradas mas emitidas com alta confiança matemática.

Métricas Comprometidas Colapso das taxas de precisão assumidas na validação original.



Comportamento Fora da Distribuição (OOD)



MÓDULO 2

Análise de Confiança

Calibração de Previsões e Anatomia do Erro

O Paradoxo da Excesso de Confiança

Modelo Bem Calibrado

A probabilidade prevista reflete a verdadeira exatidão.

Previsão de 70% = Acerto em 7 de 10 casos.

Modelo Mal Calibrado

Redes neuronais profundas tendem a gerar probabilidades extremas artificialmente.

Previsão de 99% = Acerto real inferior a 50%.

Anatomia dos Erros Práticos

Falso Positivo (Alarme Falso)

Deteção de um evento inexistente na realidade.

IMPACTO: Atuação indevida, desgaste mecânico, paragem de produção.

Falso Negativo (Omissão Crítica)

Falha na deteção de um evento real e perigoso.

IMPACTO: Risco de segurança, inércia do sistema, dano catastrófico.

Matrizes de Confusão em Cenários Críticos

O conceito de Assimetria de Custos na tomada de decisão industrial.

Previsão \ Condição Real	Estado Normal	Estado Anômalo
Prevê Normalidade	Verdadeiro Negativo	Falso Negativo (Custo Máximo)
Prevê Anomalia	Falso Positivo (Custo Moderado)	Verdadeiro Positivo

Classes Problemáticas

O fenómeno do *Long Tail* e a escassez de dados para anomalias.

Desequilíbrio Estrutural Eventos de falha são, por definição, estatisticamente raros na recolha de treino.

Viés do Otimizador A função de perda prioriza a classe maioritária (estado normal) ignorando as *edge cases*.

Limitações da Accuracy Prever sempre "Normal" garante 99% de sucesso em datasets altamente desequilibrados.

MÓDULO 3

Estratégias de Mitigação

Arquiteturas de Salvaguarda e Integração Edge

Abordagens Algorítmicas de Robustez

VETOR 01

Data Augmentation

Injeção programática de ruído, oclusões e anomalias sintéticas durante o treino.

VETOR 02

Regularização

Penalização matemática explícita contra a certeza excessiva nas previsões.

VETOR 03

Re-treino Contínuo

Adaptação periódica dos pesos para compensar o desvio temporal dos sensores.



Arquiteturas com Fallback

A inteligência preditiva exige encapsulamento dentro de sistemas determinísticos de segurança.

Safety Guards Estáticos

Limites físicos absolutos programados fora do modelo de IA.

Degradação Graciosa

Reversão automática para algoritmos de controlo heurístico em caso de incerteza.

A Mudança para On-Device ML

Vantagens críticas do processamento estritamente local.



Privacidade Nativa

Retenção integral de dados sensíveis dentro das fronteiras físicas do dispositivo.



Garantia de Latência

Eliminação da variação de rede em decisões de tempo-real crítico.



Autonomia Operacional

Resiliência absoluta contra falhas prolongadas de conectividade.

Gestão de Compromissos (Trade-offs)

O equilíbrio rigoroso dos recursos físicos de um microcontrolador.

RESTRIÇÃO I

Memória e RAM

Otimização forçada através de quantização de parâmetros (8-bit) e *pruning* estrutural.

RESTRIÇÃO II

Orçamento de Latência

Limite máximo aceitável de ciclos de relógio para garantir segurança de atuação.

RESTRIÇÃO III

Consumo Energético

Gestão térmica do SoC e preservação estrita da vida útil da bateria em nós remotos.


ESTUDO DE CASO

Análise de Falhas no Raspberry Pi

■ **Estrangulamento Térmico:** Degradação severa de performance sob inferência contínua sem dissipação ativa.

■ **Exaustão de Memória:** Competição por RAM não segmentada entre o SO hospedeiro e o modelo preditivo.

■ **Corrupção I/O:** Quedas abruptas na voltagem resultando em leituras corrompidas do barramento SPI/I2C.



Síntese da Aula

O desenvolvimento no Edge requer profissionais focados em tolerância a falhas, limites de calibração e arquiteturas redundantes, descartando a ilusão laboratorial.
